Documentación Técnica: Microservicio Auditor Recepción

Capítulo IV: Evaluación del Modelo, Pruebas de Fallo y Mantenimiento

Módulo: Auditor Recepción **Versión del Modelo:** v2.4.0 **Estado:** En Producción

1. Reporte Técnico de Métricas de Entrenamiento y Validación

El microservicio **Auditor Recepción** utiliza un modelo de clasificación supervisado para auditar la calidad, consistencia y conformidad de los productos recibidos en almacén. El modelo fue evaluado contra un conjunto de prueba compuesto por 1,200 registros etiquetados en tres categorías: *Aprobado*, *Rechazado* y *Requiere Inspección Especial (RIE)*.

96.8%	95.4%	96.1%	42 ms
PRECISIÓN GLOBAL	F1-SCORE PONDERADO	EXHAUSTIVIDAD (RECALL)	LATENCIA MEDIA (P95)

Matriz de Confusión de Validación

Resumen del comportamiento de clasificación en la etapa de validación cruzada (k=5):

Clase Real	Clase Predicha		
	Aprobado	Rechazado	RIE
Aprobado (750)	**738 (98.4%)**	4 (0.5%)	8 (1.1%)
Rechazado (300)	3 (1.0%)	**288 (96.0%)**	9 (3.0%)
RIE (150)	11 (7.3%)	5 (3.3%)	**134 (89.3%)**

2. Métricas de Rendimiento Operativo y Latencia

Las pruebas de rendimiento bajo carga simularon peticiones concurrentes de múltiples terminales de recepción en planta. El tiempo de respuesta incluye el preprocesamiento de características, la inferencia de la red y el formateo del resultado final.

Carga de Trabajo (RPS)	Latencia Media	Latencia p95	Latencia p99	Uso de Memoria (RAM)	Estado
50 RPS (Carga Normal)	18 ms	28 ms	35 ms	420 MB	Óptimo
150 RPS (Carga Alta)	27 ms	42 ms	58 ms	610 MB	Óptimo
300 RPS (Pico de Estrés)	45 ms	89 ms	120 ms	890 MB	Aceptable

3. Plan de Pruebas y Respuestas ante Fallos

Se definieron escenarios de contingencia para evaluar la resiliencia del microservicio frente a degradaciones de red, fallos en la base de datos de respaldo y corrupción en los esquemas de payload entrante.

Código / Escenario	Condición de Fallo	Respuesta Esperada del Sistema	Mecanismo de Recuperación
ERR-NET-01	Pérdida de conexión con la BD principal durante auditoría.	Activación de Circuit Breaker. Enrutamiento de logs a cola local temporal (Redis fallback).	Reconexión automática con retry exponencial. Sincronización de cola al restablecer.
ERR-MDL-02	Corrupción o indisponibilidad del archivo `.onnx` / `.pkl` del modelo.	Retorno de código HTTP 503 con fallback a regla heurística conservadora (marcar como RIE).	Carga de la versión previa estable del modelo almacenada en caché local.
ERR-PAY-03	Campos nulos o fuera de rango en la solicitud de recepción.	Retorno HTTP 400 Bad Request detallando parámetros faltantes sin interrupción del servicio.	Filtrado estricto mediante esquemas Pydantic / Validation Pipeline.
ERR-LMT-04	Saturación de memoria por peticiones masivas (>400 RPS).	Escalamiento horizontal automático de pod (HPA en Kubernetes) al superar 80% CPU/RAM.	Balanceador de carga redistribuye tráfico hacia instancias saludables.

4. Pruebas de Mantenimiento y Actualización

Para garantizar la continuidad operativa sin interrupción de las labores de recepción en almacén, se diseñaron protocolos de despliegue continuo y validación de regresión para las actualizaciones del microservicio.

Tipo de Mantenimiento	Estrategia Aplicada	Criterio de Aceptación	Frecuencia Recomendada
Reentrenamiento de Modelo	Despliegue Canary (10% tráfico inicial al nuevo modelo durante 2 horas).	Diferencial de F1-Score < 0.5% respecto al modelo base y latencia < 50ms.	Mensual o tras drift de datos > 5%.
Parches de Seguridad API	Rolling Update (actualización progresiva de réplicas sin downtime).	Cobertura de pruebas unitarias y de integración > 90% en pipeline CI/CD.	Bimensual / Según vulnerabilidades.
Optimización de BD / Caché	Depuración programada de registros históricos y reconstrucción de índices.	Tiempo de consulta a histórico de auditorías < 15 ms.	Trimestral.

Conclusión de Evaluación Técnica

El microservicio **Auditor Recepción** cumple con los estándares exigidos para operación crítica en planta. Las pruebas de estrés garantizan resiliencia y baja latencia, mientras que los protocolos de contingencia aseguran la disponibilidad continua de las auditorías de almacén.